SY09 P2025
TD/TP 0 — Introduction à NumPy et Pandas

numpy=2.2.3; **seaborn**=0.13.2; **matplotlib**=3.10.1; **pandas**=2.2.3

1 Introduction à NumPy

NumPy est une bibliothèque pour le calcul numérique en Python. Pour charger la bibliothèque, il suffit d'exécuter l'instruction suivante :

```
In  [1]: import numpy as np
```

Les fonctionnalités NumPy sont maintenant disponibles sous l'alias np.

Tableaux unidimensionnels

Création

Des tableaux unidimensionnels peuvent être créés à partir d'une simple liste Python.

```
In  [2]: a = np.array([1, 2, 3])
         b = np.array(range(7))
```

Les éléments d'un tableau NumPy doivent avoir le même type (contrairement à une liste Python). On peut contrôler le type *a posteriori* avec l'attribut dtype :

```
In  [3]: a.dtype

Out [3]: dtype('int64')
```

Si les éléments du tableau sont de types différents, les éléments sont convertis.

```
In  [4]: a = np.array([1, 2, 3, 3.14])
         a.dtype

Out [4]: dtype('float64')

In  [5]: a = np.array([1, "blah", 1.4])
         a.dtype

Out [5]: dtype('<U32')
```

On peut également spécifier le type à la création.

```
In  [6]: a = np.array([1, 2, 3], float)
         a.dtype

Out [6]: dtype('float64')
```

Il existe des fonctions prédéfinies pour créer rapidement des séquences.

1. Des séquences de nombres en spécifiant un début, une fin (exclue) et un pas :

```
In  [7]: np.arange(10)
Out [7]: array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
In  [8]: np.arange(10, 11, .1)
Out [8]: array([10. , 10.1, 10.2, 10.3, 10.4, 10.5, 10.6, 10.7, 10.8, 10.9])
```

2. Des séquences de nombres en spécifiant un début, une fin (inclue) et une longueur :

```
In  [9]: np.linspace(0, 5, 10)
Out [9]: array([0.        , 0.55555556, 1.11111111, 1.66666667, 2.22222222,
         ↪  2.77777778, 3.33333333, 3.88888889, 4.44444444, 5.        ])
```

Ou en changeant l'échelle

```
In  [10]: np.logspace(0, 2, 5)
Out [10]: array([  1.        ,   3.16227766,  10.        ,  31.6227766 ,
          ↪  100.        ])
In  [11]: np.geomspace(0.1, 100, 4)
Out [11]: array([  0.1,   1. ,  10. , 100. ])
```

1 Définir les tableaux suivants :
- $t_1 = (1, 10, 100, \ldots, 10^{10})$
- $t_2 = (0, 2, 4, \ldots, 100)$
- $t_3 = (0, -1, -2, \ldots, -10)$

```
In  [12]: np.logspace(0, 10, 11)
Out [12]: array([1.e+00, 1.e+01, 1.e+02, 1.e+03, 1.e+04, 1.e+05, 1.e+06, 1.e+07,
          ↪  1.e+08, 1.e+09, 1.e+10])
In  [13]: np.linspace(0, 100, 51)
Out [13]: array([  0.,   2.,   4.,   6.,   8.,  10.,  12.,  14.,  16.,  18.,
          ↪  20.,  22.,  24.,  26.,  28.,  30.,  32.,  34.,  36.,  38.,  40.,
          ↪  42.,  44.,  46.,  48.,  50.,  52.,  54.,  56.,  58.,  60.,  62.,
          ↪  64.,  66.,  68.,  70.,  72.,  74.,  76.,  78.,  80.,  82.,  84.,
          ↪  86.,  88.,  90.,  92.,  94.,  96.,  98., 100.])
In  [14]: np.linspace(0, -10, 11)
Out [14]: array([  0.,  -1.,  -2.,  -3.,  -4.,  -5.,  -6.,  -7.,  -8.,  -9.,
          ↪  -10.])
```

On peut également spécifier la longueur et la valeur d'initialisation.

```
In  [15]: c = np.zeros(4)
          d = np.ones(3)
          e = np.full(5, 3.8)
```

Ou alors spécifier la valeur d'initialisation et la taille d'un autre tableau.

```
In  [16]: f = np.zeros_like(d)
          g = np.ones_like(e)
          h = np.full_like(e, 2)
```

On peut également créer des tableaux suivant une loi

```
In [17]: rng = np.random.default_rng()

         i = rng.normal(loc=3, scale=2, size=1000)
         plt.hist(i)
         plt.show()
```

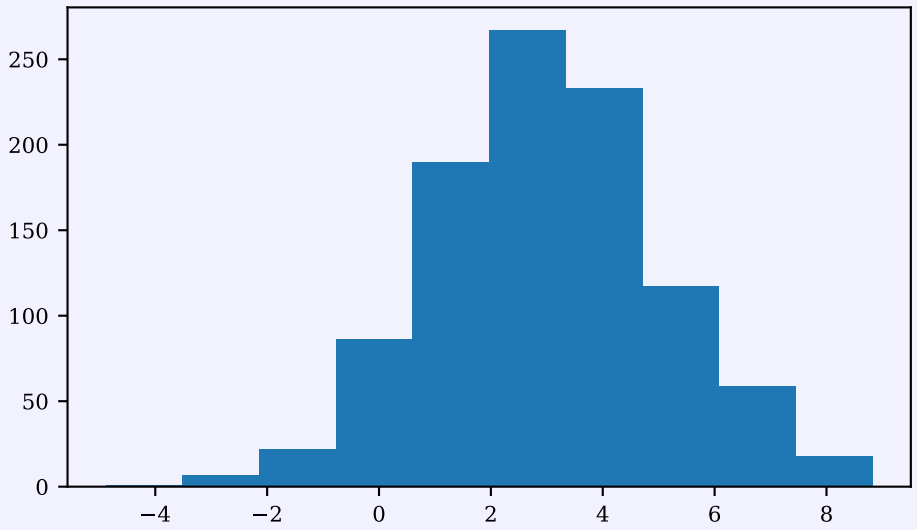


```
In [18]: j = rng.uniform(low=-1, high=1, size=1000)
         plt.hist(j)
         plt.show()
```

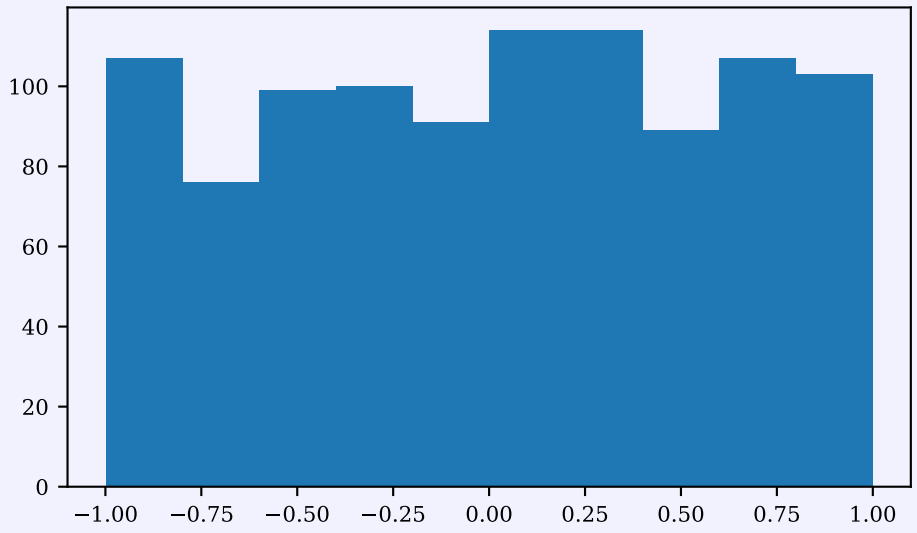

2 Créer un échantillon de longueur 1000 suivant une loi exponentielle de paramètre 0.3. Tracer son histogramme.

```
In [19]: e = rng.exponential(scale=.3, size=1000)
         plt.hist(e)
         plt.show()
```

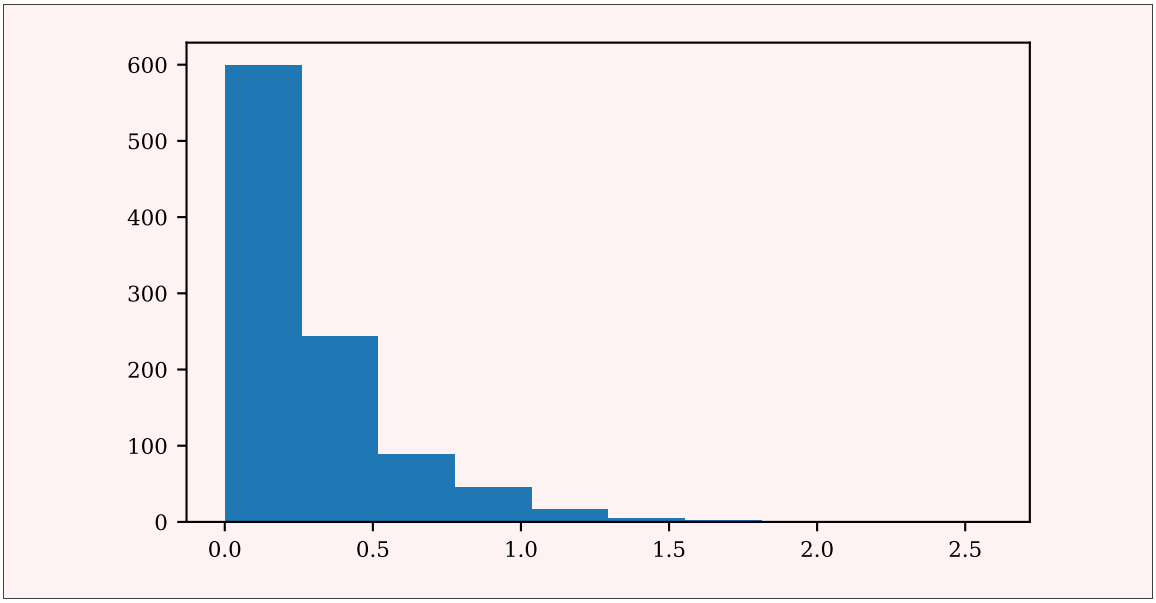

Indexation

L'extraction d'éléments ou de sous-tableaux est très similaire à la syntaxe utilisée pour les listes Python. On utilise la notation « `[]` ».

```
In  [20]: b
Out [20]: array([0, 1, 2, 3, 4, 5, 6])
In  [21]: b[2]                                    # On extrait le troisième élément
Out [21]: np.int64(2)
In  [22]: b[1:3]          # On sélectionne les indices 1 et 2, on exclut l'indice 3
Out [22]: array([1, 2])
In  [23]: b[2:]        # On coupe juste avant l'indice 2, on garde la partie droite
Out [23]: array([2, 3, 4, 5, 6])
In  [24]: b[:2]              # On coupe avant l'indice 2, on garde la partie gauche
Out [24]: array([0, 1])
In  [25]: b[:-1]     # On coupe avant le dernier indice, on garde la partie gauche
Out [25]: array([0, 1, 2, 3, 4, 5])
In  [26]: b[::2]                                  # On prend un élément sur deux
Out [26]: array([0, 2, 4, 6])
```

Les expressions précédentes peuvent également être utilisées avec des listes Python. La différence fondamentale est qu'une liste est recréée alors qu'avec `NumPy`, une « vue » sur le tableau est créée ; les données ne sont pas dupliquées. Il est alors possible d'écrire les instructions suivantes (qui produisent une erreur avec une liste Python) :

```
In  [27]: b[1:2] = 0
          b
Out [27]: array([0, 0, 2, 3, 4, 5, 6])
```

Opérations élémentaires

Les tableaux Numpy sont utilisés pour du calcul numérique, on dispose donc des opérateurs suivants :

```
In  [28]: a, d
Out [28]: (array([1., 2., 3.]), array([1., 1., 1.]))
In  [29]: a + d
Out [29]: array([2., 3., 4.])
In  [30]: a - d
Out [30]: array([0., 1., 2.])
In  [31]: a * a
Out [31]: array([1., 4., 9.])
In  [32]: a / a
Out [32]: array([1., 1., 1.])
In  [33]: 3 * a
Out [33]: array([3., 6., 9.])
In  [34]: a + 10
Out [34]: array([11., 12., 13.])
```

Opérateurs d'agrégation

```
In  [35]: a
Out [35]: array([1., 2., 3.])
In  [36]: a.sum()
Out [36]: np.float64(6.0)
In  [37]: a.mean()
Out [37]: np.float64(2.0)
In  [38]: a.min()
Out [38]: np.float64(1.0)
In  [39]: a.max()
Out [39]: np.float64(3.0)
In  [40]: a.std()
Out [40]: np.float64(0.816496580927726)
In  [41]: a.var()
Out [41]: np.float64(0.6666666666666666)
```

3 Recalculer `a.mean()` et `a.std()` en utilisant des opérations élémentaires et des opérateurs d'agrégation plus simples. Pour utiliser la fonction racine carrée, il faut la rendre disponible avec l'instruction suivante :

```
from math import sqrt
```

```
In  [42]: a.sum() / len(a)
Out [42]: np.float64(2.0)
In  [43]: from math import sqrt
          sqrt(((a - a.mean()) ** 2).mean())
Out [43]: 0.816496580927726
```

Tableaux multidimensionnels

Plus généralement, on peut créer des tableaux avec un nombre quelconque de dimensions.

Création

Des tableaux multidimensionnels peuvent être créés à partir d'une liste de listes, (de listes,…).

```
In  [44]: a = np.array([[4, 5, 6], [7, 8, 9]])
```

On peut également spécifier les dimensions et la valeur d'initialisation.

```
In  [45]: b = np.zeros((3, 4, 2))
          c = np.ones((3, 4))
          d = np.full((2, 3), 3)
```

Il existe également

```
In  [46]: rng.normal(loc=0, scale=1, size=(2, 3))
Out [46]: array([[-0.41799673,  0.22116675, -0.54013566],
                 [ 1.46501014, -0.97060498, -0.55425556]])
In  [47]: n = rng.multivariate_normal(mean=[0, 2], cov=[[2, 1], [1, 2]],
          ↪  size=100)
          plt.scatter(n[:, 0], n[:, 1])
          plt.show()
```

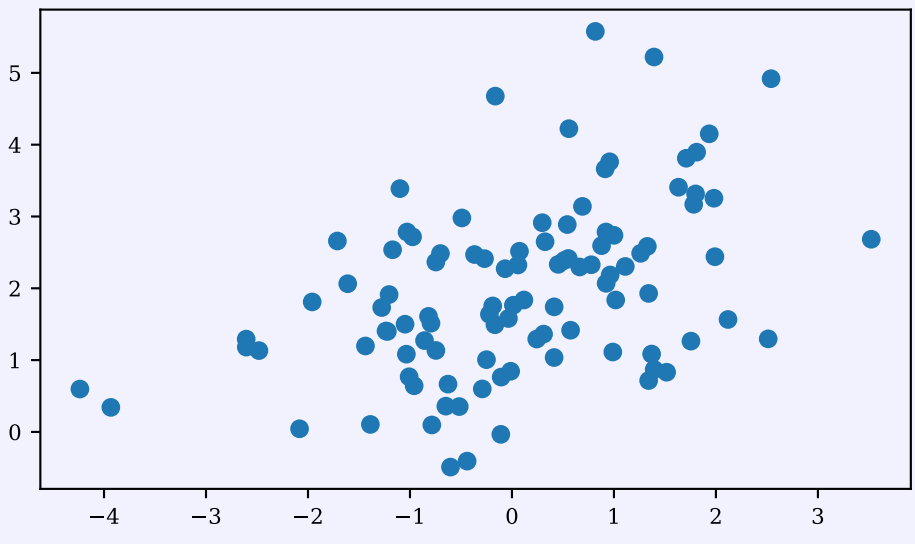

Pour les tableaux bidimensionnels (les matrices), il existe des fonctions issues de l'algèbre linéaire.

```
In  [48]: e = np.diag([1, 0, 1])          # Matrice diagonale de diagonale fixée
          f = np.eye(3)                    # Matrice identité d'ordre 3
```

Une fois créés, on peut calculer la taille des tableaux ou le nombre de dimensions

```
In  [49]: a.shape, a.ndim, b.shape, b.ndim
Out [49]: ((2, 3), 2, (3, 4, 2), 3)
```

4 Que donne la fonction longueur `len` lorsqu'on l'applique sur un tableau ?

La fonction `len` donne le nombre d'éléments de la *première* dimension. C'est l'équivalent de `a.shape[0]`

5 Créer les tableaux suivants :

$$A_1 = \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}, \qquad A_2 = \begin{pmatrix} -3 & -2 & 1 \end{pmatrix}, \qquad A_3 = \begin{pmatrix} 0 & -2 & -2 \\ -2 & 0 & -2 \\ -2 & -2 & 0 \end{pmatrix}.$$

```
In  [50]: A1 = np.array([[1], [-1], [0]])
          A2 = np.array([-3, -2, 1])
          A3 = np.full((3, 3), -2) + 2 * np.eye(3)
```

Transformations

Les tableaux peuvent être combinés entre eux de plusieurs manières.

Restructuration avec `reshape` On peut tout d'abord changer la structure d'un tableau.

```
In  [51]: a.reshape((3, 2))
Out [51]: array([[4, 5],
                 [6, 7],
                 [8, 9]])
In  [52]: a.reshape((6, 1))
Out [52]: array([[4],
                 [5],
                 [6],
                 [7],
                 [8],
                 [9]])
```

6 Utiliser la fonction `reshape` pour créer les matrices suivantes

$$A_1 = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \end{pmatrix}, \qquad A_2 = \begin{pmatrix} 1 & 3 & 5 & 7 \\ 2 & 4 & 6 & 8 \end{pmatrix}$$

```
In  [53]: (1 + np.arange(8)).reshape((2, -1))
Out [53]: array([[1, 2, 3, 4],
                 [5, 6, 7, 8]])
In  [54]: (1 + np.arange(8)).reshape((2, -1), order="F")
```

```
Out [54]: array([[1, 3, 5, 7],
                 [2, 4, 6, 8]])
```

Ajout de fausse dimension Il est souvent utile d'ajouter une fausse dimension à un tableau existant. L'exemple le plus courant est lorsqu'il s'agit de considérer un tableau unidimensionnel en une matrice ligne ou colonne.

```
In  [55]: a = np.array([1, 2, 3])
          a.shape; a.ndim

Out [55]: (3,)
          1
```

On ajoute ensuite une fausse dimension avec l'instruction `np.newaxis` :

```
In  [56]: b = a[np.newaxis, :]
          b.ndim; b.shape

Out [56]: 2
          (1, 3)

In  [57]: c = a[:, np.newaxis]
          c.ndim; c.shape

Out [57]: 2
          (3, 1)
```

L'opération inverse est possible avec la fonction `squeeze`.

```
In  [58]: b.squeeze()

Out [58]: array([1, 2, 3])

In  [59]: c.squeeze()

Out [59]: array([1, 2, 3])
```

7 Écrire une fonction qui transforme une matrice colonne en une matrice ligne.

```
In  [60]: def transpose_vector(v):
              return v.squeeze()[np.newaxis, :]

          a = np.array([[1], [2], [3]])
          transpose_vector(a)

Out [60]: array([[1, 2, 3]])
```

Concaténation avec `np.concatenate` Il s'agit de « coller » deux tableaux selon une dimension. Les tableaux doivent avoir le *même nombre de dimensions*.

```
In  [61]: a = np.array([1, 2, 3])
          b = np.array([4, 5, 6])
          np.concatenate((a, b))

Out [61]: array([1, 2, 3, 4, 5, 6])
```

Lorsque les tableaux ont plusieurs dimensions, il faut indiquer sur quelle dimension on souhaite concaténer via l'argument `axis`. Par défaut, la concaténation se fait selon la première dimension. On peut concaténer selon la dernière dimension en spécifiant `axis=-1`.

```
In  [62]: a = np.array([[1, 2, 3], [4, 5, 6]])
          b = np.array([[7, 8, 9], [10, 11, 12]])
          np.concatenate((a, b), axis=0)

Out [62]: array([[ 1,  2,  3],
                 [ 4,  5,  6],
                 [ 7,  8,  9],
                 [10, 11, 12]])

In  [63]: np.concatenate((a, b))

Out [63]: array([[ 1,  2,  3],
                 [ 4,  5,  6],
                 [ 7,  8,  9],
                 [10, 11, 12]])

In  [64]: np.concatenate((a, b), axis=1)

Out [64]: array([[ 1,  2,  3,  7,  8,  9],
                 [ 4,  5,  6, 10, 11, 12]])

In  [65]: np.concatenate((a, b), axis=-1)

Out [65]: array([[ 1,  2,  3,  7,  8,  9],
                 [ 4,  5,  6, 10, 11, 12]])
```

8 Soient A_1 et A_2 deux matrices carrées. Écrire une fonction qui renvoie la matrice suivante

$$\begin{pmatrix} A_1 & -A_2 \\ A_2 & A_1 \end{pmatrix}.$$

```
In  [66]: def matrix(A1, A2):
              A = np.concatenate((A1, -A2), axis=1)
              B = np.concatenate((A2, A1), axis=1)
              return np.concatenate((A, B), axis=0)

          matrix(np.diag([1, 2]), np.diag([3, 4]))

Out [66]: array([[ 1,  0, -3,  0],
                 [ 0,  2,  0, -4],
                 [ 3,  0,  1,  0],
                 [ 0,  4,  0,  2]])
```

9 Soit A une matrice et v un vecteur colonne et λ un scalaire. Écrire une fonction qui renvoie la matrice suivante

$$\begin{pmatrix} A & v \\ v^T & \lambda \end{pmatrix}.$$

```
In  [67]: def matrix2(A, v, lbd):
              Av = np.concatenate((A, v[:, np.newaxis]), axis=1)
              vlbd = np.concatenate((v, [lbd]))
              return np.concatenate((Av, vlbd[np.newaxis, :]))


          matrix2(np.diag([1, 2]), np.array([3, 4]), 5)

Out [67]: array([[1, 0, 3],
                 [0, 2, 4],
                 [3, 4, 5]])
```

(10) Écrire une fonction qui prend en argument la première ligne de la matrice circulante suivante

$$C = \begin{pmatrix} c_0 & c_1 & c_2 & \dots & c_{n-1} \\ c_{n-1} & c_0 & c_1 & & c_{n-2} \\ c_{n-2} & c_{n-1} & c_0 & & c_{n-3} \\ \vdots & & & \ddots & \vdots \\ c_1 & c_2 & c_3 & \dots & c_0 \end{pmatrix},$$

et renvoie cette matrice. On pourra commencer par générer la matrice C sans sa dernière colonne, la fonction `np.tile` pourra être utile.

```
In  [68]: def circulant(row):
              n = len(row)
              rows = np.tile(row, n - 1)
              c = rows.reshape((n, n - 1))
              c = np.concatenate((c, np.array(row)[::-1, np.newaxis]), axis=1)
              return c

          circulant(np.arange(6))

Out [68]: array([[0, 1, 2, 3, 4, 5],
                  [5, 0, 1, 2, 3, 4],
                  [4, 5, 0, 1, 2, 3],
                  [3, 4, 5, 0, 1, 2],
                  [2, 3, 4, 5, 0, 1],
                  [1, 2, 3, 4, 5, 0]])
```

Empilement avec `np.stack` Lorsqu'on souhaite « empiler » des tableaux, on ajoute une nouvelle dimension. Il faut alors utiliser la fonction `np.stack`.

```
In  [69]: a = np.array([1, 2])
          b = np.array([3, 4])
          np.stack((a, b))

Out [69]: array([[1, 2],
                 [3, 4]])
```

```
In  [70]: a = np.diag([1, 2, 3])
          b = np.diag([4, 5, 6])
          c = np.stack((a, b))
          c

Out [70]: array([[[1, 0, 0],
                  [0, 2, 0],
                  [0, 0, 3]],

                 [[4, 0, 0],
                  [0, 5, 0],
                  [0, 0, 6]]])

In  [71]: c.shape

Out [71]: (2, 3, 3)
```

Par défaut la dimension rajoutée est en première position. L'argument `axis` permet de changer ce comportement. La valeur -1 veut dire la dernière dimension.

```
In  [72]: c = np.stack((a, b), axis=-1)
          c
```

```
Out [72]: array([[[1, 4],
                  [0, 0],
                  [0, 0]],

                 [[0, 0],
                  [2, 5],
                  [0, 0]],

                 [[0, 0],
                  [0, 0],
                  [3, 6]]])

In  [73]: c.shape

Out [73]: (3, 3, 2)

In  [74]: d = np.stack((a, b), axis=1)
          d

Out [74]: array([[[1, 0, 0],
                  [4, 0, 0]],

                 [[0, 2, 0],
                  [0, 5, 0]],

                 [[0, 0, 3],
                  [0, 0, 6]]])

In  [75]: d.shape

Out [75]: (3, 2, 3)
```

Opérations algébriques

Lorsque les tableaux sont unidimensionnels, on peut calculer le produit scalaire.

```
In  [76]: a = np.array([1, 2, 3]); b = np.array([4, 5, 6])
          np.dot(a, b)

Out [76]: np.int64(32)
```

Pour des tableaux bidimensionnels

```
In  [77]: c = np.array([[1, 2], [3, 4]])
          d = np.array([[0, 1], [1, 0]])
          c @ d                                          # Produit matriciel

Out [77]: array([[2, 1],
                 [4, 3]])

In  [78]: np.matmul(c, d)

Out [78]: array([[2, 1],
                 [4, 3]])

In  [79]: np.transpose(c)

Out [79]: array([[1, 3],
                 [2, 4]])

In  [80]: d.transpose()

Out [80]: array([[0, 1],
                 [1, 0]])
```

```
In  [81]: d.T

Out [81]: array([[0, 1],
                 [1, 0]])

In  [82]: c ** 2                                    # Produit case-à-case !

Out [82]: array([[ 1,  4],
                 [ 9, 16]])

In  [83]: np.trace(c)                                          # La trace

Out [83]: np.int64(5)
```

11 Écrire une fonction permettant de créer une matrice A de taille $n \times p$ telle que $A_{ij} = 1/(ij)$. On remarquera que si u et v sont deux vecteurs de taille n et p alors uv^T est une matrice de taille $n \times p$ telle que $\left[uv^T\right]_{ij} = u_i v_j$

```
def matrix(n, p):
    # Définir la fonction ici
```

```
In  [84]: def matrix(n, p):
              u = (1 + np.arange(n)).reshape(n, -1)
              v = (1 + np.arange(p)).reshape(p, -1)
              return 1 / (u @ v.T)
```

2 Découverte de Pandas

`Pandas` est une bibliothèque Python qui permet de manipuler et analyser des structures de données.

Pour commencer, il faut charger la bibliothèque `Pandas` avec l'instruction suivante.

```
In  [85]: import pandas as pd
```

Une convention largement utilisée est d'importer `Pandas` sous le raccourci `pd`. Toutes les fonctionnalités de `Pandas` seront donc accessibles à travers ce raccourci.

2.1 Structure de données Pandas

2.1.1 Les séries

La première structure de données fournie par `Pandas` est une collection d'objets de même type appelée une *série*.

Création On peut les définir à partir d'une liste Python ou d'un tableau unidimensionnel `NumPy` :

```
In  [86]: a = pd.Series([1, 2, 3])
          b = pd.Series(["foo", "bar", "baz"])
          c = np.array([1, 2, 3])
          d = pd.Series(c)
```

Si jamais on souhaite convertir une série en un tableau unidimensionnel `NumPy` :

```
In  [87]: a = pd.Series([1, 2, 3])
          a.to_numpy()

Out [87]: array([1, 2, 3])
```

On peut donner un nom à la série

```
In  [88]: b = pd.Series(["foo", "bar", "baz"], name="Nom")
```

L'index Une différence majeure avec un tableau unidimensionnel est qu'une série `Pandas` dispose d'un *index* : une collection d'étiquettes qui repère chaque élément de la série. Lorsque ces étiquettes ne sont pas fournies, `Pandas` utilise les nombres entiers à partir de zéro.

```
In  [89]: pd.Series(["foo", "bar", "baz"])

Out [89]: 0    foo
          1    bar
          2    baz
          dtype: object
```

Pour fournir cet index, il suffit d'utiliser l'argument `index`.

```
In  [90]: age = pd.Series(
              [23, 24, 24, 25],
              index=["Agathe", "Béatrice", "Cédric", "Donna"]
          )
          age

Out [90]: Agathe      23
          Béatrice    24
          Cédric      24
          Donna       25
          dtype: int64
```

Pour retourner à l'index par défaut (avec des entiers à partir de 0), on utilise

```
In  [91]: age.reset_index(drop=True)

Out [91]: 0    23
          1    24
          2    24
          3    25
          dtype: int64
```

Pour changer l'index, on affecte simplement l'attribut `index`.

```
In  [92]: age.index = ["Ag", "Bé", "Cé", "Do"]
          age

Out [92]: Ag    23
          Bé    24
          Cé    24
          Do    25
          dtype: int64
```

Accès On peut accéder aux éléments d'une série de deux manières différentes :

1. Grâce aux étiquettes formant l'index. On utilise alors la méthode `loc`.
2. En utilisant la position absolue des éléments dans la série. On utilise alors la méthode `iloc`.

```
In  [93]: a = pd.Series(["Un", "Deux", "Trois"], index=[1, 2, 3])
          a.loc[1]

Out [93]: 'Un'

In  [94]: a.iloc[1]
```

```
Out [94]: 'Deux'
```

En utilisant `loc` ou `iloc`, on peut extraire de plusieurs manières :

```
In  [95]: age = pd.Series(
              [23, 24, 24, 25],
              index=["Agathe", "Béatrice", "Cédric", "Donna"],
              name="Age"
          )
```

— Directement en donnant un élément de l'index pour extraire l'élément correspondant

```
In  [96]: age.loc["Agathe"]

Out [96]: np.int64(23)

In  [97]: age.loc["Cédric"]

Out [97]: np.int64(24)

In  [98]: age.iloc[0]

Out [98]: np.int64(23)

In  [99]: age.iloc[-1]

Out [99]: np.int64(25)
```

— En fournissant une liste d'éléments de l'index pour extraire une sous-série

```
In  [100]: age.loc[["Agathe", "Donna"]]

Out [100]: Agathe    23
           Donna     25
           Name: Age, dtype: int64

In  [101]: age.iloc[[1, 3]]

Out [101]: Béatrice    24
           Donna       25
           Name: Age, dtype: int64
```

— En utilisant la notation *slice*

```
In  [102]: age.iloc[:-1]

Out [102]: Agathe      23
           Béatrice    24
           Cédric      24
           Name: Age, dtype: int64

In  [103]: age.iloc[2:]

Out [103]: Cédric    24
           Donna     25
           Name: Age, dtype: int64

In  [104]: age.loc["Cédric":]

Out [104]: Cédric    24
           Donna     25
           Name: Age, dtype: int64

In  [105]: age.loc["Béatrice":"Donna"]
```

```
Out [105]: Béatrice    24
           Cédric      24
           Donna       25
           Name: Age, dtype: int64

In  [106]: age.loc["Agathe":"Donna":2]

Out [106]: Agathe    23
           Cédric    24
           Name: Age, dtype: int64
```

— En fournissant un masque : un tableau de booléen de même taille que la série.

```
In  [107]: masque = [True, False, False, True]
           age.loc[masque]

Out [107]: Agathe    23
           Donna     25
           Name: Age, dtype: int64
```

Le masque peut également être une série de booléens de même index.

```
In  [108]: masque = pd.Series([True, False, False, True])
           masque.index = age.index
           masque

Out [108]: Agathe       True
           Béatrice    False
           Cédric      False
           Donna        True
           dtype: bool

In  [109]: age.loc[masque]

Out [109]: Agathe    23
           Donna     25
           Name: Age, dtype: int64
```

À noter que les masques sont rarement fournis directement sous forme d'un tableau ou d'une série de booléens. Ils sont plutôt construit directement à partir d'une autre série voire de la série elle-même.

```
In  [110]: masque = age > 23
           masque

Out [110]: Agathe      False
           Béatrice     True
           Cédric       True
           Donna        True
           Name: Age, dtype: bool

In  [111]: age.loc[masque]

Out [111]: Béatrice    24
           Cédric      24
           Donna       25
           Name: Age, dtype: int64
```

12 Charger la série avec la commande suivante.

```
s1 = pd.read_csv("data/s1.csv", index_col=0, squeeze=True)
```

Construire les séries suivantes :

— La liste des prénoms donnés plus de 100000 fois
— L'effectif total des prénoms précédant `SACHA`

```
In  [112]: s1 = pd.read_csv("data/s1.csv", index_col=0).squeeze()
           s1.loc[s1 > 100000].index

Out [112]: Index(['LUCAS', 'EMMA'], dtype='object', name='preusuel')

In  [113]: s1.loc[:"SACHA"].sum()

Out [113]: np.int64(3231384)
```

2.1.2 Les *DataFrame*

La structure de données la plus utilisée est le tableau individu–variable. `Pandas` les modélise avec la classe `pd.DataFrame`. Il s'agit d'une collection d'objets de type `pd.Series` représentant les colonnes d'un tableau individu–variable.

Création On peut construire des *DataFrame* de plusieurs manières :
— en fournissant un dictionnaire dont les clés sont les noms des caractéristiques et les valeurs sont des listes Python, des tableaux unidimensionnels `NumPy` ou des séries `Pandas` représentant les caractéristiques.

```
In  [114]: col1 = np.array([23, 24, 24, 25])
           col2 = ["Agathe", "Béatrice", "Cédric", "Donna"]
           pd.DataFrame({
             "Age": col1,
             "Nom": col2
           })

Out [114]:    Age       Nom
           0   23    Agathe
           1   24  Béatrice
           2   24    Cédric
           3   25     Donna

In  [115]: age = pd.Series([23, 24, 24, 25])
           nom = pd.Series(["Agathe", "Béatrice", "Cédric", "Donna"])
           pd.DataFrame({
             "Age": age,
             "Nom": nom
           })

Out [115]:    Age       Nom
           0   23    Agathe
           1   24  Béatrice
           2   24    Cédric
           3   25     Donna
```

Attention, l'index de chaque série est utilisé pour construire un index commun

```
In  [116]: age = pd.Series([23, 24, 24, 25], index=[0, 1, 2, 3])
           nom = pd.Series(["Agathe", "Béatrice", "Cédric", "Donna"],
           ↪  index=[2, 3, 4, 5])
           pd.DataFrame({
             "Age": age,
             "Nom": nom
           })
```

```
Out [116]:     Age       Nom
           0  23.0       NaN
           1  24.0       NaN
           2  24.0    Agathe
           3  25.0  Béatrice
           4   NaN    Cédric
           5   NaN     Donna
```

— à partir d'un générateur. `Pandas` s'attend à ce que chaque élément généré soit une ligne du tableau individu–variable.

```
In  [117]: def gen():
               yield "Agathe", 23
               yield "Béatrice", 24
               yield "Cédric", 24
               yield "Donna", 25

           pd.DataFrame(gen())

Out [117]:           0   1
           0    Agathe  23
           1  Béatrice  24
           2    Cédric  24
           3     Donna  25
```

— à partir d'un fichier `csv` qu'on charge à l'aide la fonction `pd.read_csv`.

```
In  [118]: pd.read_csv("data/s1.csv")

Out [118]:     preusuel  nombre
           0      LUCAS  117001
           1       EMMA  105209
           2       ENZO   97980
           3        LÉA   96491
           4       HUGO   91960
           ..       ...     ...
           995   KELIAN    1984
           996      JAD    1983
           997   THELMA    1982
           998  MANELLE    1981
           999    KESSY    1972

           [1000 rows x 2 columns]
```

Pour convertir un *DataFrame* en un tableau bidimensionnel `NumPy`, on peut faire appel à la fonction `to_numpy()` :

```
In  [119]: col1 = np.array([23, 24, 24, 25])
           col2 = ["Agathe", "Béatrice", "Cédric", "Donna"]
           df = pd.DataFrame({
             "Age": col1,
             "Nom": col2
           })
           df.to_numpy()

Out [119]: array([[23, 'Agathe'],
                  [24, 'Béatrice'],
                  [24, 'Cédric'],
                  [25, 'Donna']], dtype=object)
```

Attention cependant au type utilisé pour le tableau `NumPy`, ici `object` pour tous les éléments.

Informations utiles

```
In  [120]: col1 = np.array([23, 24, 24, 25])
           col2 = ["Agathe", "Béatrice", "Cédric", "Donna"]
           df = pd.DataFrame({
             "Age": col1,
             "Nom": col2
           })
           df.columns

Out [120]: Index(['Age', 'Nom'], dtype='object')

In  [121]: df.shape

Out [121]: (4, 2)

In  [122]: len(df)

Out [122]: 4

In  [123]: df.dtypes

Out [123]: Age     int64
           Nom    object
           dtype: object
```

La plupart des informations ci-dessus sont synthétisées lors de l'appel à `info()`

```
In  [124]: df.info()

Out [124]: <class 'pandas.core.frame.DataFrame'>
           RangeIndex: 4 entries, 0 to 3
           Data columns (total 2 columns):
            #   Column  Non-Null Count  Dtype
           ---  ------  --------------  -----
            0   Age     4 non-null      int64
            1   Nom     4 non-null      object
           dtypes: int64(1), object(1)
           memory usage: 196.0+ bytes
```

L'index Les *DataFrame* dispose également d'un index commun à toutes les colonnes pour repérer tout individu (une ligne) dans le tableaux individus-variables.

On peut changer l'index à partir d'une colonne existante.

```
In  [125]: df

Out [125]:    Age       Nom
           0   23    Agathe
           1   24  Béatrice
           2   24    Cédric
           3   25     Donna

In  [126]: df.set_index("Nom")

Out [126]:            Age
           Nom
           Agathe      23
           Béatrice    24
           Cédric      24
           Donna       25
```

Accès On peut extraire les colonnes sous forme de séries de plusieurs manières :

— Si le nom de colonne est un nom d'attribut valide (pas d'espace ou caractères spéciaux…)

```
In  [127]: df.Age

Out [127]: 0    23
           1    24
           2    24
           3    25
           Name: Age, dtype: int64
```

— De manière plus générale

```
In  [128]: df["Age"]

Out [128]: 0    23
           1    24
           2    24
           3    25
           Name: Age, dtype: int64
```

Pour extraire plusieurs colonnes, il suffit de donner la liste

```
In  [129]: df[["Age", "Nom"]]

Out [129]:    Age       Nom
          0   23    Agathe
          1   24  Béatrice
          2   24    Cédric
          3   25     Donna
```

Pour extraire des enregistrements (lignes), on utilise `loc` et `iloc`

```
In  [130]: df.loc[df.Age >= 24]

Out [130]:    Age       Nom
          1   24  Béatrice
          2   24    Cédric
          3   25     Donna

In  [131]: df.iloc[[2, 3]]

Out [131]:    Age     Nom
          2   24  Cédric
          3   25   Donna
```

On peut également combiner les deux types d'extraction

```
In  [132]: df.loc[df.Age >= 24, ["Age"]]

Out [132]:    Age
          1   24
          2   24
          3   25
```

Modification Ajout/suppression de colonnes

```
In  [133]: df.drop(columns=["Age"])

Out [133]:        Nom
          0    Agathe
          1  Béatrice
          2    Cédric
          3     Donna
```